

Nüfus ve Sosyal Araştırmalar Enstitüsü

Yapay Zeka Modülü : Makine Öğrenmesi Ders 9: Pekiştirmeli Öğrenmeye Giriş Eğitmen:

Ercan Atam

Bu notlar, Ercan Atam hocanın sunumunu temel almakla birlikte; Pekiştirmeli Öğrenmenin arkasındaki ileri düzey istatistiksel konseptler, optimizasyon problemleri ve eksik bırakılan teorik ispatlarla zenginleştirilmiştir.

1 - Pekiştirmeli Öğrenme Paradigması ve Kredi Atama Problemi

Makine öğrenmesi evreninde Pekiştirmeli Öğrenme (RL), klasik denetimli ve denetimsiz öğrenmeden tamamen farklı bir felsefeye dayanır. RL'de hazır bir doğru etiket yoktur; bir ajan çevreyle girdiği etkileşimler ve deneme-yanılma mekanizması ile kendi verisini kendisi üretir.

Ekstra İleri Seviye Bilgi (Kredi Atama Problemi): Pekiştirmeli öğrenmeyi diğer yöntemlerden matematiksel olarak çok daha zor kılan şey gecikmiş ödül olgusudur. Örneğin, AlphaGo bir Go maçını kazandığında (ödül +1), maç boyunca 150 hamle yapmıştır. Modelin asıl çözmesi gereken optimizasyon problemi şudur: "Bu +1 ödülü, geçmişte yaptığım 150 hamleye nasıl ve hangi ağırlıklarla dağıtmalıyım? Hangi hamlem gerçekten iyiydi, hangisi sadece şanstı?" RL algoritmalarının temel varoluş amacı bu kredi atama problemini istatistiksel olarak çözmektir.

1.1 Temel Etkileşim Döngüsü

Sistem, zamanın ayrık adımlarla ($t = 0, 1, 2, \dots$) aktığı bir karar sürecidir:

1. **Durum (S_t):** Ajanın t anında içinde bulunduğu matematiksel veya fiziksel koşullar.
2. **Eylem (A_t):** Ajanın duruma tepki olarak seçtiği hamle.
3. **Ödül (R_{t+1}):** Çevrenin eyleme verdiği tepkisel, skaler puan.

Bu döngü, istatistiksel bir zaman serisi yörüngesi üretir:

$$\tau = S_0, A_0, R_1, S_1, A_1, R_2, \dots$$

2 - Çevre, Gözlemlenebilirlik ve Hafıza İhtiyacı

Ajanın çevreyi nasıl algıladığı, problemin matematiksel sınırlarını belirler.

- **Tam Gözlemlenebilirlik:** Ajanın sensörleri, çevrenin tüm durumunu eksiksiz olarak okur ($Y_t = S_t^e$). Satranç tahtasının tamamını görmek buna örnektir. Bu durumda problem standart bir Markov Karar Sürecidir.
- **Kısmi Gözlemlenebilirlik:** Ajan, çevrenin sadece bir kısmını algılar ($Y_t \neq S_t^e$). Sisli bir yolda giden otonom araç veya rakiplerin kartlarının kapalı olduğu bir poker oyunu bu sınıftadır.

Ekstra Algoritmik Bilgi (Kısmi Gözlemlenebilirliği Çözmek): Kısmi gözlemlenebilirlik durumunda ajan, mevcut eksik gözlemiyle doğrudan karar veremez çünkü Markov varsayımı çökmüştür. Bunu çözmek için ajan, geçmiş gözlemlerini tuttuğu bir inanç durumu oluşturmalıdır. Modern Derin Pekiktirmeli Öğrenmede, bu sorunu aşmak için sinir ağının içine LSTM veya GRU gibi tekrarlayan katmanlar eklenerek ajana bir kısa süreli hafıza kazandırılır.

3 - Getiri, İskonto Oranı ve Zaman Değeri Paritesi

Ajan anlık ödülü değil, gelecekteki tüm ödüllerin toplamını (Getiri - G_t) maksimize etmeye çalışır.

3.1 Sonsuz Ufuk ve γ İskontosu

Bölümlü görevlerde süreç bittiği için ödüller toplanabilir. Ancak sürekli görevlerde süreç sonsuza gittiği için ödüllerin basit toplamı ıraksar. Bu nedenle iskonto oranı (γ) kullanılır:

$$G_t = \sum_{i=0}^{\infty} \gamma^i R_{t+i+1}$$

Ekstra İstatistiksel ve Finansal Mantık (Neden İskonto Yaparız?): $\gamma \in [0, 1]$ parametresi sadece seriyi matematiksel olarak yakınsatmakla kalmaz, üç temel gerçeği modeller:

1. **Geleceğin Belirsizliği:** Gelecekteki 10 puanlık ödülün gerçekleşme ihtimali, şu anki 10 puan kadar kesin değildir. Tıpkı finansta paranın zaman değeri olması gibi, ödülün de zaman değeri vardır.
2. **Sınırlı Bellek:** γ değerini küçültmek, modelin varyansını düşürür. Çok uzun vadeli tahminler çok yüksek istatistiksel gürültü barındırır.
3. **Miyopluk Kontrolü:** $\gamma = 0$ modeli tamamen kısa görüşlü yapar. $\gamma \rightarrow 1$ ise modeli uzun vadeli bir satranç ustasına dönüştürür.

4 - Keşfetme ve Sömürme İkilemi

Makine öğrenmesindeki en meşhur denge probleimidir. Ortam başlangıçta kara kutudur.

- **Sömürme:** O anki en iyi bilgiyle, maksimum ödülü getirecek eylemi seçmek. (Yerel maksimuma takılma riski barındırır).
- **Keşfetme:** Modelin, daha yüksek bir ödül yolu bulma umuduyla mevcut stratejisinden sapıp yeni şeyler denemesidir.

Ekstra Algoritmik Çözümler (Bu Denge Nasıl Kurulur?): Bu ikilem rastgele çözülmez. Çözüm için kullanılan popüler matematiksel stratejiler şunlardır:

1. **ϵ -Açgözlü:** Model $(1 - \epsilon)$ olasılıkla sömürme yapar, ϵ olasılıkla tamamen rastgele keşfetme yapar. Eğitim ilerledikçe ϵ değeri sıfıra doğru çürütülür.
2. **Softmax Yaklaşımı:** Model eylemleri doğrudan rastgele seçmez. Q-değerlerine dayalı bir Boltzmann dağılımı oluşturur. İyi eylemlerin seçilme şansı daha yüksektir, ama kötü eylemlerin de seçilme şansı sıfır değildir.
3. **Üst Güven Sınırı (UCB):** Belirsizlik karşısında iyimserlik felsefesine dayanır. Bir eylem ne kadar az denenmişse, istatistiksel olarak belirsizlik o kadar yüksektir ve algoritma sırf bu belirsizliği gidermek için o eylemi denemeye zorlanır.

5 - Markov Karar Süreçleri ve Markov Özelliği

Tüm pekiştirmeli öğrenme kuramı, MDP adı verilen 5 bileşenli bir (S, A, P, R, γ) sistemine dayanır. En kritik bileşenler modelin dinamiğini oluşturan P (Geçiş Matrisi) ve R (Ödül Matrisi) yapılarıdır.

Ekstra İleri Seviye Bilgi (Markov Özelliğinin Katı Tanımı): Bir durumun Markov kabul edilebilmesi için şu istatistiksel denklemin doğrulanması şarttır:

$$\mathbb{P}(S_{t+1}|S_t, A_t, S_{t-1}, A_{t-1}, \dots) = \mathbb{P}(S_{t+1}|S_t, A_t)$$

Anlamı: Gelecek, geçmişten bağımsızdır; ancak ve ancak şu an verilmişse. Eğer mevcut S_t durumu, geçmişte olan biten her şeyin yeterli istatistiğini içinde barındırıyorsa bu süreç Markov'dur. Satranç tahtasının anlık dizilimi Markov'dur, ancak bir filmin sadece tek bir karesine bakmak Markov değildir.

6 - Politika, Değer Fonksiyonları ve Optimizallık

- **Politika (π):** Ajanın beynidir. Hangi durumda hangi eylemi seçeceğini belirler (Olasılıksal veya Deterministik).
- **Durum-Değer (V) ve Eylem-Değer (Q) Fonksiyonları:** Ajanın bulunduğu konumun veya yapacağı eylemin uzun vadede ne kadar getiri sağlayacağını beklenen değerini ($\mathbb{E}$) hesaplar.

6.1 Çekirdek Teori: Bellman Denklemleri

Ercan hocanın notlarında Bellman'ın beklenti denklemleri verilir. Bu denklemler mevcut bir politikanın değerini ölçer. Ancak asıl amaç en iyi politikayı bulmaktır.

Ekstra Matematiksel Bilgi (Bellman Optimizallik Denklemleri - V^* ve Q^*):

Pekiştirmeli öğrenmede bir problemi çözmek, Bellman Optimizallik Denklemini bulmak demektir. Bu denklemden doğrusal beklenti operatörü yerini, lineer olmayan maksimum ($\max$) operatörüne bırakır:

$$v^*(s) = \max_a \mathbb{E}[R_{t+1} + \gamma v^*(S_{t+1}) | S_t = s]$$
$$q^*(s, a) = \mathbb{E}[R_{t+1} + \gamma \max_{a'} q^*(S_{t+1}, a') | S_t = s, A_t = a]$$

Makine öğrenmesi modeli, sistemdeki tüm s ve a çiftleri için bu iteratif denklemin sol tarafı ile sağ tarafı arasındaki hatayı sıfıra indirmeye çalışarak eğitilir.

7 - Gelişmiş Ajan Sınıflandırmaları

Ajanlar, kullandıkları yaklaşımlara göre hiyerarşik olarak sınıflandırılır. Değer tabanlı, Politika tabanlı, Aktör-Eleştirmen ve Model tabanlı / Modelden bağımsız olarak dörde ayrılır.

Ekstra Endüstriyel Bilgi (On-Policy ve Off-Policy Farkı): Modelden bağımsız algoritmalar iki büyük alt kategoriye ayrılır:

1. **On-Policy Algoritmalar (Örn: SARSA, PPO):** Ajan, ortamdan veri toplarken hangi politikayı kullanıyorsa, sadece ve sadece o politikayı geliştirir. Yaptığını öğrenir. Eğitimi daha güvenli ve stabil yapar ancak veri verimliliği düşüktür. Geçmişte yapılan hatalardan ders çıkaramaz.
2. **Off-Policy Algoritmalar (Örn: Q-Learning, DQN, SAC):** Ajanın veri topladığı davranış politikası ile asıl optimize ettiği hedef politika birbirinden farklıdır. Bu, ajanın başkalarının hatalarından veya geçmişte rastgele yaptığı kendi hatalarından öğrenmesini sağlar. Veri verimliliği muazzamdır, ancak eğitimi matematiksel olarak çok daha zor ve kararsızdır. Modern otonom sistemlerde genellikle Off-Policy Derin RL algoritmaları kullanılır.

8 - Pekiştirmeli Öğrenme Algoritmalarının Evrimi

Sistem modelleri, ajanların eğitim süreçlerinde kullandıkları algoritmik temellere göre iki ana döneme ayrılır. Günümüzdeki en etkili algoritmalar Derin RL grubunda yer almaktadır.

8.1 Klasik RL Algoritmaları

Bu algoritmalar, Q-değerlerini veya durum değerlerini bir matris içinde tutarak günceller.

- **Monte Carlo:** Ajan sadece bölüm bittiğinde geriye dönük olarak değerleri günceller. Yüksek varyanslıdır ancak yanlışlık barındırmaz.
- **Fark Algoritmaları (TD):** Ajan her adımda, bölümün bitmesini beklemeden mevcut tahminini bir sonraki tahminiyle günceller.
- **SARSA:** On-Policy bir algoritmadır. Ajan, Q-değerini güncellerken gerçekten bir sonraki adımda alacağı aksiyonun değerini kullanır.
- **Q-Learning:** Off-Policy bir algoritmadır. Ajan, bir sonraki adımda ne yapacak olursa olsun, Q-değerini güncellerken o anki en iyi aksiyonun değerini hesaba katar.

Ekstra İleri Seviye Bilgi (Boyutun Laneti): Klasik RL algoritmalarının en büyük sorunu boyutun lanetidir. Eğer durum uzayınız satranç tahtası gibiye veya piksellerden oluşan bir video oyunuysa, trilyonlarca satırlık bir Q-Tablosu oluşturamazsınız. İşte bu noktada klasik RL tıkanır ve yerini Derin RL'e bırakır.

8.2 Derin RL Algoritmaları

Derin RL, Q-değerlerini bir tabloda tutmak yerine, bu değerleri tahmin etmek için yapay sinir ağlarını kullanır.

- **DQN:** Klasik Q-Learning algoritmasının sinir ağları ile birleşmiş halidir. Atari oyunlarında insan seviyesini aşan ilk devrimsel modeldir.
- **DDPG & TD3:** Sürekli eylem uzayları için geliştirilmiş Actor-Critic tabanlı algoritmalarıdır.
- **PPO:** Günümüzde LLM'lerin ve robotik uygulamaların endüstri standardı olan algoritmadır. Öğrenme adımlarını kısıtlayarak çok stabil bir eğitim sunar.
- **SAC:** Maksimum entropi felsefesini kullanır; ajanı sadece ödülü maksimize etmeye değil, aynı zamanda olabildiğince rastgele davranmaya teşvik eder.

9 - İleri Okuma Listesi

Derin RL mimarilerini kavramadan önce sağlam bir istatistiksel, matematiksel ve algoritmik temel atmak şarttır. Sunumun sonunda tavsiye edilen başucu eserleri şunlardır:

9.1 Önkoşul Matematik ve İstatistik Temeli

RL'in bel kemiği doğrusal cebir ve olasılık teorisidir.

- *Introduction to Linear Algebra* - Gilbert Strang (6. Baskı, 2023)
- *Introduction to Probability, Statistics, and Random Processes* - Hossein Pishro-Nik (2014)

9.2 Makine Öğrenmesi

- *Learning From Data* - Yaser S. Abu-Mostafa, Malik Magdon-Ismail, Hsuan-Tien Lin (2012).

- *Machine Learning: A First Course for Engineers and Scientists* - Andreas Lindholm vd. (2022)
- *Machine Learning Fundamentals: A Concise Introduction* - Hui Jiang (2022)

9.3 Pekiştirmeli Öğrenme

- **Başucu Kitabı:** *Reinforcement Learning: An Introduction* - Richard S. Sutton, Andrew G. Barto (2. Baskı, 2018).
- *Mathematical Foundations of Reinforcement Learning* - Shiyu Zhao (Springer, 2024).

-Memreu